



Trabajo Práctico
Modelos de Recuperación
de Información (y evaluación)

Fecha de entrega: 23/04/2026

Josue Leonel Gatica Odato 178921

Josuegaticaodato@gmail.com





Aclaración importante sobre colecciones:

Para un correcto manejo de las colecciones en cada ejercicio, los archivos .py tomando las colecciones por defecto en una carpeta llamada “Colecciones”, ubicada a la par con todas las carpetas de los ejercicios.

En ejercicios donde no se indica el pasaje del directorio donde se encuentran los documentos como parámetro, este toma por defecto la carpeta indicada con el nombre de la colección que se solicitó analizar para ese ejercicio.

Herramienta de IA

El modelo de lenguaje de inteligencia artificial utilizado para el trabajo fue ChatGPT



1) Dados los siguientes documentos, arme la matriz término-documento (TD)¹

- Doc1 = {El software libre ha tenido un papel fundamental en el crecimiento de Internet. Además, Internet ha favorecido la comunicación entre los desarrolladores de software y ha permitido una mayor colaboración.}
- Doc2 = {La mayor riqueza que tiene un país es la cultura, eso lo hace más libre. El acceso a Internet tiene un papel importante en la producción de conocimiento y el intercambio de información.}
- Doc3 = {La producción de software es fundamental para nuestro país, como así también lo es la producción de tecnología de hardware y comunicación. Es esencial fomentar la innovación en tecnología.}
- Doc4 = {La cultura del software libre está en crecimiento. Es fundamental que nuestro país incorpore software libre en el estado.}
- Doc5 = {El intercambio de conocimiento y la colaboración abierta son pilares de la cultura libre. La tecnología debe ser accesible para todos los ciudadanos.}
- Doc6 = {La infraestructura de Internet es vital para el crecimiento económico y la igualdad de oportunidades. El software libre contribuye a una mayor soberanía tecnológica.}

¿Qué documentos se recuperan en cada caso para las siguientes consultas booleanas? (Muestre mediante operaciones con conjuntos cómo se resuelven las consultas)

- a) (not software) or (pais and fundamental)
- b) producción and (cultura or libre)
- c) fundamental or libre or país
- d) (accesible or vital) and not (libre)

Documentos que se recuperan en cada caso para las siguientes consultas booleanas:

A) Terminos: Software – Pais -Fundamental

	d1	d2	d3	d4	d5	d6
fundamental	1	0	1	1	0	0
pais	0	1	1	1	0	0
software	1	0	1	1	0	1

Query: (not software) or (pais and fundamental)

¹ utilice la planilla disponible en https://github.com/tolosoft-academia/RI_2025/blob/main/data/Matriz_TD_base.ods



Relevantes: {D2, D3, D4, D5}

B) Términos: Producción – Cultura – Libre

	d1	d2	d3	d4	d5	d6
cultura	0	1	0	1	1	0
libre	1	1	0	1	1	1
produccion	0	1	1	0	0	0

Query: producción and (cultura o libre)

Relevantes: {D2}

C) Términos: Fundamental – Libre - País

	d1	d2	d3	d4	d5	d6
fundamental	1	0	1	1	0	0
libre	1	1	0	1	1	1
pais	0	1	1	1	0	0

Query: fundamental or libre or país

Relevantes: {D1,D2,D3,D4,D5,D6}

D) Términos: Accesible – Vital - Libre

	d1	d2	d3	d4	d5	d6
accesible	0	0	0	0	1	0
libre	1	1	0	1	1	1
NOT libre	0	0	1	0	0	0
vital	0	0	0	0	0	1

Query: (accesible or vital) and not (libre)

Relevantes: {}

Como hablamos en clase, este modelo solamente determina los modelos que pueden ser más relevantes para la consulta, no se obtienen scores ni rankings para obtener aquellos que pueden ser más o menos relevantes que otros.

Utilización de IA:

Para construir de una forma más efectiva la matriz termino-documento, se le solicito a la IA una formula en Excel para obtener la existencia o no del término dentro de los documentos. Esa fórmula es la siguiente:



**=SI(ESNUMERO(HALLAR(" "&\$A2&" "; SUSTITUIR(SUSTITUIR(" "&\$L\$2&" "; ","; "
"); "."; " "))); 1; 0)**

Fue necesario una revisión de las palabras que estaban en la query para confirmar que la formula hacia lo correcto.



2) Utilizando los documentos del ejercicio anterior, arme la matriz TD pero calculando w_{ij} como la frecuencia del i-ésimo término en el j-ésimo documento. Calcule el ranking para las siguientes consultas utilizando como métrica el producto escalar y luego repita con la métrica del coseno.

- a) software pais fundamental
- b) producción cultura libre
- c) fundamental libre país
- d) accesible vital libre

Cálculo del ranking para las consultas:

A) Terminos: Software – Pais – Fundamental

	d1	d2	d3	d4	d5	d6
fundamental	1	0	1	1	0	0
pais	0	1	1	1	0	0
software	2	0	1	2	0	1

Query: software pais fundamental

Producto escalar:

Q1	doc	d1	d2	d3	d4	d5	d6
	score	3	1	3	4	0	1

Utilizando el producto escalar, el documento con más similitud a la query es D4.

Rankings: D4,D3-1,D2-6,D5

Cosenos:

Q1	doc	d1	d2	d3	d4	d5	d6
	score	0,775	0,577	1,000	0,943	#DIV/0!	0,577

Rankings: D3,D4,D1-2,D6,D5

A través de la similitud con cosenos, el documento D3 tiene un score de 1, siendo este idéntico a la Query.

Ambas similitudes dieron documentos con más score distintos, ya que el producto escalar favoreció al documento que tiene los términos con más apariciones, mientras que la



similitud por coseno beneficio al documento D3 que tiene la misma cantidad de ocurrencias para los tres términos.

B) Terminos: Produccion – Cultura - Libre

	d1	d2	d3	d4	d5	d6
cultura	0	1	0	1	1	0
libre	1	1	0	2	1	1
produccion	0	1	2	0	0	0

Query: produccion cultura libre

Producto escalar:

Q2	doc	d1	d2	d3	d4	d5	d6
	score	1	3	2	3	2	1

Rankings: D2-4, D3-5, D6-1

El producto escalar determina como más relevantes D2 y D4.

Cosenos:

Q2	doc	d1	d2	d3	d4	d5	d6
	score	0,577	1,000	0,577	0,775	0,816	0,577

Rankings: D2, D5, D4, D1-3-6

La similitud por coseno determina que el documento más relevante es D2, y a este le sigue D5.

El producto escalar solamente sumo la cantidad de ocurrencias que tuvieron todos los términos en los documentos, haciendo que D2 y D4 sean los que tengan mayor score.

En cambio, en cosenos, D4 tiene menos score ya que el término “producción” no está presente en el documento y el término “libre” tiene dos apariciones. En D5, dos términos aparecen solamente una vez, haciendo que sea más similar a la query y este mas balanceado. Por último, D2 tiene todos los términos de la query con frecuencia uno, haciendo que sea el que más rankings tiene.



C) Terminos: Fundamental – Libre - Pais

	d1	d2	d3	d4	d5	d6
fundamental	1	0	1	1	0	0
libre	1	1	0	2	1	1
pais	0	1	1	1	0	0

Query: fundamental libre pais

Producto escalar:

Q3	doc	d1	d2	d3	d4	d5	d6
	score	2	2	2	4	1	1

Rankings: D4, D1-2,-3, D5-6

El producto escalar determina como top 1 del ranking a el D4 por tener frecuencia 4 de los terminos en la query.

Cosenos:

Q3	doc	d1	d2	d3	d4	d5	d6
	score	0,816	0,816	0,816	0,943	0,577	0,577

Rankings: D4, D1-2-3, D5-6

La similitud por coseno elige como mejor documento a D4, al igual que el producto escalar.

En este caso, existe un ranking exacto entre ambas similitudes, ya que D1/D2/D3 tienen la misma distribución de frecuencia en términos, donde 2 de 3 términos tienen frecuencia 1, y el término que resta no está presente en el documento. Con D5 y D6 sucede lo mismo, pero solamente uno de los términos está presente en la query, y tiene frecuencia 1. El que mejor score tiene, que es D4 en ambos casos, predomina frente a los demás ya que tiene la presencia de todos los términos en el documento frente a la query.



D) Términos: Accesible – Vital - Libre

	d1	d2	d3	d4	d5	d6
accesible	0	0	0	0	1	0
libre	1	1	0	2	1	1
vital	0	0	0	0	0	1

Query: accesible vital libre

Producto escalar:

Q4	doc	d1	d2	d3	d4	d5	d6
	score	1	1	0	2	2	2

Rankings: D4-5-6, D1-2, D3

El producto escalar determina como más relevantes a D4,D5 y D6

Cosenos:

Q4	doc	d1	d2	d3	d4	d5	d6
	score	0,577	0,577	#¡DIV/0!	0,577	0,816	0,816

Rankings: D5-6, D1-2-4, D3

La similitud por coseno elimina como más relevante a uno de los tres documentos que el producto escalar determina con mayor score, ya que D4 solamente tiene presente el término “libre” en el documento. En cambio, D5 y D6 tienen presentes 2 de 3 términos que están en la query dentro del documento. Entonces, la similitud por cosenos favorece documentos más similares a la query, y no la cantidad de ocurrencias de todos los términos dentro del documento.

Resultados generales:

producto escalar							
Q1	doc	d1	d2	d3	d4	d5	d6
	score	3	1	3	4	0	1
Q2	doc	d1	d2	d3	d4	d5	d6
	score	1	3	2	3	2	1
Q3	doc	d1	d2	d3	d4	d5	d6
	score	2	2	2	4	1	1
Q4	doc	d1	d2	d3	d4	d5	d6
	score	1	1	0	2	2	2
cosenos							
Q1	doc	d1	d2	d3	d4	d5	d6
	score	0,775	0,577	1,000	0,943	#DIV/0!	0,577
	norma	2,236	1,000	1,732	2,449	0,000	1,000
Q2	doc	d1	d2	d3	d4	d5	d6
	score	0,577	1,000	0,577	0,775	0,816	0,577
	norma	1,000	1,732	2,000	2,236	1,414	1,000
Q3	doc	d1	d2	d3	d4	d5	d6
	score	0,816	0,816	0,816	0,943	0,577	0,577
	norma	1,414	1,414	1,414	2,449	1,000	1,000
Q4	doc	d1	d2	d3	d4	d5	d6
	score	0,577	0,577	#DIV/0!	0,577	0,816	0,816
	norma	1,000	1,000	0,000	2,000	1,414	1,414

Utilización de IA:

Al igual que el ejercicio anterior, se le solicito a la IA una fórmula para realizar el conteo de las frecuencias para cada término, obteniendo lo siguiente:

**=(LARGO(SUSTITUIR(SUSTITUIR(" "&L\$2&" "; ","; " "); ". "; " ")) -
LARGO(SUSTITUIR(MINUSC(SUSTITUIR(SUSTITUIR(" "&L\$2&" "; ","; " "); ". "; " "));
MINUSC(" "&A45&" "); ""))) / LARGO(" "&A45&" ")**

Fue necesario una revisión de los términos que estaban en la query para confirmar que la formula hacia lo correcto.



- 3) Rearme la matriz del ejercicio anterior, pero calcule los pesos de acuerdo a TF/IDF. Repita todas las consultas (por ambos modelos de similitud). ¿Puede obtener alguna conclusión?

En este ejercicio, se usó TF/IDF como forma de ponderación. El cálculo del mismo se realizó de la siguiente manera:

Para el cálculo del TF/IDF de cada término, se utilizó la siguiente formula:

$$\log \frac{N}{n_i}$$

Donde:

- N: Cantidad de documentos totales
- Ni: Cantidad de documentos que tiene el término i.

Luego, se construyó una nueva matriz termino-documento de TF/IDF, usando lo siguiente:

$$w_{i,j} = \begin{cases} (1 + \log f_{i,j}) \times \log \frac{N}{n_i} & \text{if } f_{i,j} > 0 \\ 0 & \text{otherwise} \end{cases}$$

Cálculos el ranking para las consultas (usando TF/IDF)

A) Terminos: Software – Pais – Fundamental

	d1	d2	d3	d4	d5	d6
fundamental	0,301	0,000	0,301	0,301	0,000	0,000
pais	0,000	0,301	0,301	0,301	0,000	0,000
software	0,229	0,000	0,176	0,229	0,000	0,176

Query: software pais fundamental

Producto escalar:

Q1	doc	d1	d2	d3	d4	d5	d6
	score	0,131	0,091	0,212	0,222	0,000	0,031

Rankings: D4, D3, D1, D2, D6, D5

Para el producto escalar, el documento más relevante es D4, siguiendo a D3.

En comparativa con el ejercicio anterior, D4 sigue siendo el más relevante, aunque el score de D1 y D3 es diferente.



Cosenos:

Q1	doc	d1	d2	d3	d4	d5	d6
	score	0,751	0,653	1,000	0,995	#DIV/0!	0,382

Rankings: D3, D4, D1, D2, D6, D5

Para cosenos, D3 es quien tiene el score más alto, siendo lo más similar a la Query posible. Le sigue D4, donde el producto escalar había identificado como de mayor similitud.

Esto puede explicarse por el valor que presenta el término “software”. La ponderación por $TF \cdot IDF$ hizo que este término pese menos por aparecer en más documento (4 en total, a comparación de los otros dos términos que aparecen 3 veces), haciendo que D3 pase a ser más relevante por presentarlo solamente una vez.

B) Términos: Producción – Cultura – Libre

	d1	d2	d3	d4	d5	d6
cultura	0,000	0,301	0,000	0,301	0,301	0,000
libre	0,079	0,079	0,000	0,103	0,079	0,079
produccion	0,000	0,477	0,621	0,000	0,000	0,000

Antes de llevar a cabo las similitudes, puede verse como “producción” es el término más pesado de todos, haciendo que sea de gran relevancia.

Query: produccion cultura libre

Producto escalar:

Q2	doc	d1	d2	d3	d4	d5	d6
	score	0,006	0,325	0,296	0,099	0,097	0,006

Rankings: D2, D3, D4, D5, D6-1

El producto escalar determina con mayor scoring a D2 por contener todos los términos. Es por eso que supera a D3. En el ejercicio anterior, había un empate entre D2 y D4 como mejor score.

Cosenos:

Q2	doc	d1	d2	d3	d4	d5	d6
	score	0,139	1,000	0,838	0,545	0,546	0,139



Rankings: D2, D3, D4-5, D6-1

La similitud por coseno, al igual que el producto escalar, determina que D2 es el documento con mejor score, exacto a la query. Este sobresale de los demás por tener presente los 3 términos de la query.

Se destaca también el alto valor de score de D3, a pesar de solamente tener presente el término “producción” en su corpus. Esto nos hace concluir que un solo termino muy importante puede competir contra varios poco importante.

C) Terminos: Fundamental – Libre – Pais

	d1	d2	d3	d4	d5	d6
fundamental	0,301	0,000	0,301	0,301	0,000	0,000
libre	0,079	0,079	0,000	0,103	0,079	0,079
pais	0,000	0,301	0,301	0,301	0,000	0,000

Los términos fundamental y país son importantes en este caso por tener mucho peso.

Query: fundamental libre pais

Producto escalar:

Q3	doc	d1	d2	d3	d4	d5	d6
	score	0,097	0,097	0,181	0,189	0,006	0,006

Rankings: D4, D3, D1-2, D5-6

El producto escalar favorece a D4 por tener los tres términos presente, haciendo que tenga el mayor peso total, derivando en el mejor score.

Cosenos:

Q3	doc	d1	d2	d3	d4	d5	d6
	score	0,719	0,719	0,983	0,999	0,183	0,183

Rankings: D4, D3, D1-2, D5-6

D4 supera a D3 en score por tener presente el término “libre”, haciendo que este mas alineado a la query. De igual manera, al ser este término de poco peso, la diferencia de score es mínima.

D1 y D2 le siguen a estos dos primeros documentos por tener uno de los términos más importantes en la query, que es “fundamental”, acompañado de un término menos raro, “libre”, que tiene poca influencia a comparación de los otros dos.



D) Términos: Accesible – Vital – Libre

	d1	d2	d3	d4	d5	d6
accesible	0,000	0,000	0,000	0,000	0,778	0,000
libre	0,079	0,079	0,000	0,103	0,079	0,079
vital	0,000	0,000	0,000	0,000	0,000	0,778

Puede verse como la presencia de “accesible” y “vital” en el documento va a ser determinante para el scoring, ya que son los términos más influyentes.

Query: accesible vital libre

Producto escalar:

Q4	doc	d1	d2	d3	d4	d5	d6
	score	0,006	0,006	0,000	0,008	0,612	0,612

Rankings: D5-6, D4, D1-2, D3

D5 y D6 tienen un término poco influyente (“libre”) y un término con mucho peso en su corpus (“accesible” en D5, “vital” en D6), provocando que ambos sean los mejores rankeados.

Cosenos:

Q4	doc	d1	d2	d3	d4	d5	d6
	score	0,072	0,072	#¡DIV/0!	0,072	0,709	0,709

Rankings: D5-6, D1-2-4, D3

Como se mencionó en el producto escalar, ambos tienen un término con mucho peso en su corpus, y son los únicos dos documentos que los tienen. Esto hace que un solo término raro pueda dominar todo el ranking.

La significativa distancia con sus scores siguientes se debe a la falta de términos relevantes en su corpus. Por ejemplo, D4 solamente tiene “libre”, que es el menor significativo en este estudio.



Resultados generales:

producto escalar							
Q1	doc	d1	d2	d3	d4	d5	d6
	score	0,131	0,091	0,212	0,222	0,000	0,031
Q2	doc	d1	d2	d3	d4	d5	d6
	score	0,006	0,325	0,296	0,099	0,097	0,006
Q3	doc	d1	d2	d3	d4	d5	d6
	score	0,097	0,097	0,181	0,189	0,006	0,006
Q4	doc	d1	d2	d3	d4	d5	d6
	score	0,006	0,006	0,000	0,008	0,612	0,612
cosenos							
Q1	doc	d1	d2	d3	d4	d5	d6
	score	0,751	0,653	1,000	0,995	#DIV/0!	0,382
	norma	0,378	0,301	0,461	0,483	0,000	0,176
Q2	doc	d1	d2	d3	d4	d5	d6
	score	0,139	1,000	0,838	0,545	0,546	0,139
	norma	0,079	0,570	0,621	0,318	0,311	0,079
Q3	doc	d1	d2	d3	d4	d5	d6
	score	0,719	0,719	0,983	0,999	0,183	0,183
	norma	0,311	0,311	0,426	0,438	0,079	0,079
Q4	doc	d1	d2	d3	d4	d5	d6
	score	0,072	0,072	#DIV/0!	0,072	0,709	0,709
	norma	0,079	0,079	0,000	0,103	0,782	0,782



- 4) Utilizando pyTerrier, indexe la colección Wiki-Small². Tome 5 necesidades de información y, de forma manual, derive una consulta (*query*). Para cada una, pruebe la recuperación por los modelos basados en TF/IDF y BM25. ¿Cómo se comportan los rankings? Calcule el coeficiente de correlación para los primeros 10, 25 y 50 resultados. ¿Qué conclusiones obtiene?

Armamos las 5 necesidades de información solicitadas (en español, luego las consultas serán en inglés):

- Que sucedió en Montreal, Canada en 1838?
- Asteroide de 1994
- Que fue la guerra mundial?
- Cuantos lenguajes tiene Wikipedia?
- Quienes fueron los foo fighters?

En base a ellas, llevamos a cabo la construcción de 5 consultas para los modelos de recuperación:

1. canada 1838
2. asteroid 1994
3. wikipedia languages
4. world war
5. foo fighters

Probando los modelos de recuperación, obtuvimos el ranking para cada query, pudiendo analizar lo siguiente:


- En todas las queries (menos la 3), el orden de los documentos es el mismo o casi igual. No varía mucho el ranking pero si el score.
Podemos decir que hay una alta correlación entre ambos modelos en los primeros niveles del rankings. Esto se confirma a la hora de calcular el coeficiente de correlación más adelante.
- Los documentos que devuelven los modelos son coherentes a la necesidad de información. Por ejemplo, el top 1 de “asteroid 1994” devuelve exactamente un enlace a Wikipedia de un asteroide descubierto en esa fecha.
- En la query 4, el orden de los documentos entre ambos documentos cambia ligeramente, confirmando que BM25 considera la saturación de los términos

² <http://dg3rtljivitrle.cloudfront.net/wiki-small.tar.gz>

- En la query 3, se rompe esa correlación entre ambos modelos al utilizar un término que aparece en todos los documentos ("Wikipedia") con uno que es menos discriminativo ("Languages").

Todos los documentos que devolvió TF-IDF tienen como título Languages. En cambio, BM25 devolvió documento con scores negativos y sin contener este término como nombre de documento.

Para finalizar el análisis, se calculó el coeficiente de correlación para los primeros 10, 25 y 50 resultados.



Como puede verse en el gráfico, a medida que aumenta el Top, hace que la correlación entre ambos modelos sea mayor, concluyendo que estos construyen rankings muy similares. Esto se puede deber a las queries que se utilizaron para llevar a cabo el análisis, que son bastantes claras para ambos modelos y devuelven resultados coherentes.

```
[{'qid': '1', 'k': 10, 'correlation': 0.9999999999999999},
 {'qid': '1', 'k': 25, 'correlation': 0.9961538461538462},
 {'qid': '1', 'k': 50, 'correlation': 0.9972850678733031},
 {'qid': '2', 'k': 10, 'correlation': 0.9999999999999999},
 {'qid': '2', 'k': 25, 'correlation': 1.0},
 {'qid': '2', 'k': 50, 'correlation': 0.9990396158463385},
 {'qid': '3', 'k': 10, 'correlation': -0.8583690987124465},
 {'qid': '3', 'k': 25, 'correlation': -0.8573388203017832},
 {'qid': '3', 'k': 50, 'correlation': -0.8571918395336877},
 {'qid': '4', 'k': 10, 'correlation': 0.9454545454545454},
 {'qid': '4', 'k': 25, 'correlation': 0.9900000000000001},
 {'qid': '4', 'k': 50, 'correlation': 0.9975030012004802},
 {'qid': '5', 'k': 10, 'correlation': 0.9999999999999999},
 {'qid': '5', 'k': 25, 'correlation': 1.0},
 {'qid': '5', 'k': 50, 'correlation': 0.9999999999999999}]
```

Analizando los resultados de correlación de cada query y sus tops, puede verse como la query 3, nombrada anteriormente por devolver documentos completamente distintos, tiene una relación muy negativa, provocando que la correlación en general entre los modelos



no sea uno por esta query. Podemos decir que la query 3 genera un problema para ambos modelos a la hora de llevar a cabo la recuperación, y es necesario analizarla en detalle para obtener los resultados esperados.

Utilización de IA:

Para facilitar la construcción de gráficos de correlación por top-K, se le solicito a la IA que realice el código del mismo, llevando a cabo la supervisión correspondiente para que haga lo correcto.

5) Escriba un *script* que lea un directorio con documentos de texto y arme una estructura de datos en memoria para soportar la recuperación. Luego, debe permitir ingresar una consulta y devolver un ranking de los documentos relevantes utilizando el modelo vectorial. Use TF/IDF según MIR [1]: $(1 + \log(\text{freq}_{i,j})) \times \log(N / n_i)$

5.1) Indexe la colección del ejercicio 4 con su software. Ejecute las consultas y compare los resultados con los obtenidos con pyTerrier. ¿Son consistentes?

Se construyo una estructura de datos en memoria que soporta recuperación, que almacena los datos de la siguiente manera:

```
Término: 'biographical'
DF: 2
Postings:
-> Doc: w\Edwin_Norris_d733.html | Peso TF-IDF: 3.0681
-> Doc: _\Ed_Stokes_5982.html | Peso TF-IDF: 3.0681
```

Cada termino del vocabulario tiene su DF junto con la posting-list a los documentos que está presente ese término, y el TF-IDF correspondiente

Construida la estructura, debió a la gran cantidad de términos que tiene la colección Wiki-Small, se seleccionó un pequeño conjunto útil de esta para probar queries entre la librería y el script construido.

La query en este caso fue la primera utilizada en el ejercicio 4, que fue “canada 1838 montreal”. El resultado para pyTerrier fue el siguiente:

```
Query 1: canada 1838 montreal

TF-IDF:

```

	docno	score	rank
0	w\Edwin_Moses_0128.html	4.142192	0
1	m\Edmonton_municipal_election_1937.html	1.817851	1
2	6\0\t\60th_World_Science_Fiction_Convention_56...	1.692664	2

Mientras que, el script construido, devolvió lo siguiente:

```
Escriba una opcion: 1
Consulta: Canada 1838 Montreal
6\0\t\60th_World_Science_Fiction_Convention_56da.html 0.24112876462076524
w\Edwin_Moses_0128.html 0.2243933015321371
```



Utilizando la estructura de recuperación de posting, fue posible recuperar 2 de los 3 documentos relevantes que destaco la librería, con un score y orden bastante diferente a lo que se esperaba. La justificación ante esto seria las técnicas que utiliza atrás el algoritmo de pyTerrier para construir sus índices, además de aplicar stemming, stopwords propias, normalización, etc.

A pesar de las diferencias con la librería, se pude construir un pequeño índice que cumple con los requerimientos solicitados.

Utilización de IA:

Fue necesaria la utilización de IA para construir la estructura de datos de memoria que soporte recuperación.

6) Se requiere evaluar la performance en la recuperación de un sistema. Para una consulta q_1 , dicho sistema entregó la siguiente salida:

1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
R	N	N	R	R	N	N	N	N	R	N	N	N	R	N

Los documentos identificados como R son los relevantes, mientras que las N's corresponden a documentos no relevantes a q_1 . Suponga, además, que existen en el corpus otros 6 documentos relevantes a q_1 que el sistema no recuperó. A partir de esta salida, calcule las siguientes medidas:

- Recall y Precisión para cada posición j .
- Precisión promedio.
- Precisión al 50 % de Recall.
- Precisión-R.
- DCG@10, IDCG@10 y nDCG@10
- MRR

Finalmente, realice las gráficas interpolada y sin interpolar. Luego, interprete brevemente los resultados y brinde una explicación.

Total Relevantes	Relevantes Recuperados	Total Recuperados	Precisión	Recall
11	5	15	0.33	0.45

Precisión = 0,33. Uno de cada tres documentos recuperados es relevantes
Recall = 0,45. El sistema recupero un 45% de todos los documentos relevantes.

A) Recall y Precisión por cada posición j

	Documento	Relevante	Recall	Precisión
1	1	SI	$1/11 = 0.091$	1
2	2	NO	0.091	0.5
3	3	NO	0.091	0.333
4	4	SI	$2/11 = 0.18$	0.5
5	5	SI	$3/11 = 0.27$	0.6
6	6	NO	0.27	0.5
7	7	NO	0.27	0.42
8	8	NO	0.27	0.375
9	9	NO	0.27	0.333
10	10	SI	$4/11 = 0.36$	0.4
11	11	NO	0.36	0.36
12	12	NO	0.36	0.33



13	13	NO	0.36	0.307
14	14	SI	5/11 = 0.45	0.357
15	15	NO	0.45	0.333

Con verde, indico la aparición de un documento relevante en la posición.

Como puede verse en el gráfico, se hace visible el tradeoff entre Recall y Precisión donde, a medida que uno sube, el otro baja.

B) Precisión Promedio

Se calcula en posiciones donde hay relevantes. El resultado sería:

Posiciones relevantes: 1,4,5,10,14

$$(1 + 0,5 + 0,6 + 0,4 + 0,357) / 11 = \mathbf{0.259}$$

Como es un valor bajo, podemos decir que los relevantes se encuentran muy dispersos.

C) Precisión al 50% de Recall

El recall nunca llego al 50%. Esto nos da una idea de que la cobertura de todos los documentos relevantes capturados por el sistema no es muy buena.

Este problema puede solucionarse con los 6 documentos relevantes que el sistema no recupero. Con recuperar un relevante más tenemos un 54% de Recall, o modificando el orden del ranking puede llegarse a la franja que necesitamos.

D) Precisión-R

El cálculo es:

$$(\text{relevantes en el top R}) / R$$

Donde R es el número total de relevantes (11 en nuestro caso)

El resultado sería:

$$R\text{-Precisión} = 4 / 11 = \mathbf{0.364}$$

E)

DCG@10

Relevantes en posiciones: 1, 4, 5, 10

En todos los casos, el grado de relevancia es 1.

$$DCG_p = rel_1 + \sum_{i=2}^p \frac{rel_i}{\log_2 i}$$

- $i = 1 \rightarrow 1$
- $i = 4 \rightarrow 1/\log_2 (4) = 0,5$
- $i = 5 \rightarrow 1/\log_2 (5) = 0,431$
- $i = 10 \rightarrow 1/\log_2 (10) = 0,301$

La sumatoria da como resultado **2.232**

IDCG@10

El mejor caso, donde los primeros 10 son relevantes.

Como todos tienen grado de relevancia 1, el cálculo es el siguiente:

- $i = 1 \rightarrow 1$
- $i = 2 \rightarrow 1/\log_2 (2) = 1$
- $i = 3 \rightarrow 1/\log_2 (3) = 0,631$
-
- $i = 10 \rightarrow 1/\log_2 (10) = 0,301$

Toda esta sumatoria da como resultado **5.254**

nDCG@10

$$nDCG = \frac{DCG}{iDCG}$$

$$nDCG = (DCG / iDCG) = (2,232/5,254) = 0.425$$

Al ser un número menor que 1, podemos decir que tiene un mal ordenamiento, haciendo que no sea un buen ranking.

F) MRR (Mean Reciprocal Rank)

Mide la capacidad de un sistema para posicionar el primer resultado relevante lo más alto posible en una lista ordenada. Formula:

$$MRR = \frac{1}{|U|} \sum_{u=1}^U \frac{1}{rank_u}$$

- $|Q|$: Número total de consultas
- Rank: Posición del primer documento relevante para la i-esima consulta.
- $1/Rank$: Es el rango reciproco.

En este caso, como el primer relevante está en la posición 1. **El resultado del MRR es 1.**

Como es uno, quiere decir que el primer resultado es relevante para el usuario.

Gráfico interpolado





Gráfico sin interpolar



Analizando ambos gráficos, puede verse como lo fuerte del sistema es la recuperación del primer documento como relevante, que fue calculado en el MRR. Esto hace que a medida que aumenten los documentos baje considerablemente la precisión, siendo cero a partir del sexto documento.



En el grafico sin interpolar, pueden verse los picos cada vez que aparece un documento relevante en el sistema, pero no resultan lo suficiente como para aumentar la precisión del mismo.

Utilización de IA:

Se le solicito a la inteligencia artificial la construcción de las grafica interpolada y no interpolada del sistema a través de un pequeño labo en Python, con el fin de hacer más énfasis en el análisis de las métricas y no en el código que genera el grafico.

7) Utilizando la colección de prueba Vaswani y pyTerrier se debe realizar la evaluación del sistema. Para ello, es necesario construir un índice con los documentos de la colección y luego ejecutar las consultas (modelo vectorial con TF/IDF), las cuales deben armar a partir de los términos que considere de las necesidades de información (puede eliminar las palabras vacías). Los resultados deben ser comparados contra los juicios de relevancia de la colección. Realizar el análisis en dos ámbitos:


- Global (promedio de todas la consultas), para las siguientes métricas: P@10, AP, NDCG@10 e incluya la gráfica de R-P en los 11 puntos estándar.
- Individual (por query), para las mismas métricas, calculando la distribución de los valores en cada caso.

A) Análisis global

Los resultados para las métricas solicitadas fueron las siguientes:

Métrica	Valor	Análisis
P@10	0.3591	De los primeros 10 resultados, casi 4 documentos son relevantes. El valor es aceptable, pero ver el P@5 podría ser más interesante para acompañar esta métrica.
AP	0.2909	Al ser un valor bajo, los documentos relevantes se mezclan con los no relevantes.
NDCG@10	0.4444	El valor es menor que 1, por lo que estaría mal el ordenamiento de los relevantes.

Luego de calcular las métricas, construimos la curva R-P de 11 puntos.




Mirando la curva, puede verse la precisión es alta en bajos valores de recall, llegando a un pico de 0.72 como máximo. Luego, esta decrece hasta 0.02, perdiendo casi toda la precisión pero con un recall de 1.

Podes decir que el sistema recupera buenos resultados al principio, pero cuando aumenta la cantidad de documentos este deja de serlo, perdiendo efectividad.

B) Análisis Individual

Para el análisis por query, se muestra gráficamente como es la distribución de los valores en cada métrica.

P@10




X: Valores de la métrica – Y: Cantidad de querys

Para el P@10, puede verse que la mayor cantidad de querys que tiene en el top 10 los documentos más relevantes son entre 0,1 y 0,4. Esto quiere decir que, de 10 documentos, hay entre 1 a 4 documentos relevantes.

Existen muy pocas querys que se recupera una gran cantidad de documentos relevantes, como 8 de 10 documentos, que son solamente 2 a 3 querys.

Podemos concluir que el sistema recupera pocos documentos relevantes en el top 10, y eso lo confirmamos con el análisis global visto anteriormente.

AP




X: Valores de la métrica – Y: Cantidad de queries

La gran cantidad de queries rondan entre valores de 0.0 a 0.6, y existen unas pocas queries que tienen valor 0.7.

Concluimos que el sistema tiene un rendimiento inconsistente a lo largo de las consultas

NDCG@10



X: Valores de la métrica – Y: Cantidad de queries

Existen muchos valores de 0.5 a 0.8, y también existen una gran cantidad de casos con 0.0. Hay una dispersión notable de las queries en este caso.

Mirando la gráfica, es posible partir a la distribución en dos mitades bien marcadas, de 0.0 a 0.4 abarcaría una parte, que es la mala, mientras que 0.5 a 0.8 sería la otra, que es la moderada-buena.



Con esta dispersión, podemos decir que el orden del ranking es algún casos es muy bueno, mientras que la otra mitad no ordena de forma correcta los relevantes encontrados, y eso explica los valores bajísimos en la otra mitad.

8) Dadas las salidas de tres sistemas de recuperación de información para 3 consultas cualquiera³ y los juicios de relevancia creados por asesores humanos⁴ calcule para cada sistema:

- La precisión media
- La precisión media a intervalos de Recall de 20%
- P@5, P@10, P@20


Luego, exponga un escenario posible y medidas complementarias para decidir qué sistema utilizar.

Cálculos en planilla "Ejer-Evaluacion-OUTPUT". En cada hoja están las query, y dentro de ellas los tres sistemas con las métrica solicitadas.

Análisis por Query:

- Para la query 1, el mejor sistema resulta ser el A por tener una buena precisión media y altos valores de precisión para tops altos. Le sigue el sistema B que presenta valores no tan distintos que A, y por ultimo C que tiene niveles muy bajos en comparativa al primero, un 30% menor.

- SISTEMA A**
- Sistema B
- Sistema C




- Para la query 2, sigue siendo dominante el sistema A por las mismas razones que la query anterior (buena precisión media + precisión alta en tops altos). El sistema C se superpone levemente contra el sistema B en este caso

- SISTEMA A**
- Sistema C
- Sistema B


³ https://github.com/tolosoft-academia/RI_2025/blob/main/data/Ejer-Evaluacion-OUTPUT.ods

⁴ https://github.com/tolosoft-academia/RI_2025/blob/main/da1/ta/Ejer-Evaluacion-JR.ods



3. Para la query 3, en desempeños generales, el sistema B mínimamente es mejor que los demás, pero ninguno de los tres es relativamente bueno como lo era A en las dos anteriores queries.

- 1) **SISTEMA B**
- 2) Sistema A
- 3) Sistema C



En conclusión, el mejor sistema a utilizar es el Sistema A, ya que tiene muy buenas métricas para 2 de las 3 queries realizadas. Además, destaca en tener buena precisión en tops de resultados 5 y 10, destacándolo en entornos donde los primeros resultados son muy relevantes para el usuario.

Para ayudar con el estudio, serian necesario agregar medidas complementarias vistas en clase como el MAP, para obtener el promedio de los AP de todas las queries, y el nDCG, ya que puedo evaluar el ranking con relevancias. En forma gráfica, se podría usar el promedio de los valores interpolados de las tres consultas para comparar los tres sistemas.

Utilización de IA:

Se le solicito a la inteligencia artificial las fórmulas para la planilla necesarias para llevar a cabo la construcción de las métricas solicitadas en el ejercicio.



Bibliografía

- [1] Ricardo Baeza-Yates and Berthier Ribeiro-Neto. Modern Information Retrieval: The Concepts and Technology Behind Search. Addison-Wesley Publishing Company, USA, 2nd edition, 2008.
- [2] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. Introduction to Information Retrieval. Cambridge University Press, New York, NY, USA, 2008.