



Trabajo Práctico
**Modelos de Recuperación
de Información (Parte 2)**

Fecha de entrega: 06/05/2026

Josue Leonel Gatica Odató 178921

Josuegaticaodato@gmail.com





Aclaración importante sobre colecciones:

Para un correcto manejo de las colecciones en cada ejercicio, los archivos .py tomando las colecciones por defecto en una carpeta llamada “Colecciones”, ubicada a la par con todas las carpetas de los ejercicios.

En ejercicios donde no se indica el pasaje del directorio donde se encuentran los documentos como parámetro, este toma por defecto la carpeta indicada con el nombre de la colección que se solicitó analizar para ese ejercicio.

Herramienta de IA

El modelo de lenguaje de inteligencia artificial utilizado para el trabajo fue ChatGPT



1) Retome el TP de "Modelos de RI" y calcule el modelo de lenguaje (unigramas) para los documentos del ejercicio 2. Utilizando el modelo de Query Likelihood calcule los rankings para las siguiente consultas:

- a) país cultura
- b) país libre cultura
- c) software propietario licencia

¿Qué problemas encuentra? Luego, calcule las probabilidades de los términos utilizando una combinación con el ML de la colección (suavizado Jelinek-Mercer, $\lambda = 0,7$). Compare con las probabilidades anteriores y explique las diferencias. Repita las consultas con los nuevos valores. Explique los resultados.

Utilizando la planilla de cálculo del ejercicio 2, se construyó el modelo de lenguaje (unigrama) para los documentos

Documento	d1	d2	d3	d4	d5	d6
Total de términos	15	14	13	9	12	13

El total de términos del documento se obtuvo realizando la sumatoria de los TF de cada termino en ese documento.

Cálculo de rankings

Para utilizar el modelo de Query Likelihood, fue necesaria la construcción de una nueva matriz termino-documento de MLE, indicando cual es la probabilidad de ocurrencia del término en ese documento. La fórmula es la siguiente:

$$P(t|\theta_i) = \frac{f(t, d_i)}{|d_i|}$$

A) Consulta: país cultura

cultura	0,000	0,071	0,000	0,111	0,083	0,000
pais	0,000	0,071	0,077	0,111	0,000	0,000

El modelo Query likelihood propone, dada una consulta, rankear los documentos acorde a la probabilidad de que cada documento genere la query. La fórmula es:

$$P(q|d_i) = P(q|\theta_i) = \prod_{t \in q} P(t|\theta_i)$$



El ranking de documentos quedo de la siguiente manera:

doc	d1	d2	d3	d4	d5	d6
score	0,000	0,005	0,000	0,012	0,000	0,000

El documento d4 tiene el mejor score por tener país y cultura en su corpus, y supera a d2 porque ambos términos tienen mayor probabilidad. Los demás documentos tienen score cero por no contener uno o ninguno de los dos términos en su corpus.

B) Consulta: país libre cultura

cultura	0,000	0,071	0,000	0,111	0,083	0,000
libre	0,067	0,071	0,000	0,222	0,083	0,077
país	0,000	0,071	0,077	0,111	0,000	0,000

El ranking de documentos quedo de la siguiente manera:

doc	d1	d2	d3	d4	d5	d6
score	0,000	0,000364	0,000	0,002743	0,000	0,000

Agregando el término “libre” a la consulta anterior, el score de D2 y D4 baja, porque están condicionados a tener, en mayor o menor medida, la probabilidad de ocurrencia de ese término dentro del documento. De igual manera, D4 sigue siendo el mejor documento para este modelo.

A medida que agrego términos, se vuelve más difícil que un documento los tenga a todos, haciendo que el ranking sea bastante pobre y no tenga una buena capacidad para recuperar documentos relevantes.

C) Consulta: software propietario licencia

Los términos “propietario” y “licencia” no estaban presente en la matriz, y tampoco en ninguno de los documentos. Es interesante recalcarlo para deducir el porqué de los resultados del score.

software	0,133	0,000	0,077	0,222	0,000	0,077
propietario	0,000	0,000	0,000	0,000	0,000	0,000
licencia	0,000	0,000	0,000	0,000	0,000	0,000

El ranking de documentos quedo de la siguiente manera:

doc	d1	d2	d3	d4	d5	d6
score	0,000000	0,000000	0,000000	0,000000	0,000000	0,000000



Todos los score dieron cero, haciendo que ningún documento sea relevante para la consulta.

Esto se explica ya que, como se mencionó anteriormente, los dos términos no aparecen en ningún documento, y a la hora de hacer el cálculo del ranking, la no presencia de por lo menos un término dentro del documento hace que el score sea cero, eliminando al documento como relevante.

Por lo tanto, el modelo de Query likelihood no puede rankear si hay términos fuera del vocabulario, siendo muy estricto a la presencia necesaria de términos dentro del documento.

Suavizado Jelinek-Mercer

Aplicando este suavizado, interpolamos el modelo del documento con el de la colección. La fórmula es la siguiente:

$$P_{JM}(t|\theta_i) = \lambda \cdot P_{MLE}(t|\theta_i) + (1 - \lambda) \cdot P_{MLE}(t|\theta_C)$$

En este caso, es necesario estimar la probabilidad de cada termino en la colección, que es el segundo término de la ecuación. Este se calcula de la siguiente manera:

$$P_{MLE}(t|\theta_C) = \frac{\sum_{d_i \in C} f(t, d_i)}{|C|}$$

Construida la matriz con este suavizado, podemos ver cómo ningún termino tiene probabilidad cero, a excepción de los dos últimos términos que fueron agregados a la matriz, que no están presentes en ninguno de los seis documentos. Esto quiere decir que el suavizado distribuye la probabilidad hacia términos que son poco frecuentes o que no están presentes en todos los documentos.

Que toda la matriz tenga una probabilidad asociada hace que sea distinto al modelo de unigramas, ya que solo consideraba la probabilidad de aparición del término o no dentro del documento, siendo cero siempre que no esté presente.

A) Consulta: país cultura

	d1	d2	d3	d4	d5	d6	P(Term Coleccion)
cultura	0,0118	0,0618	0,0118	0,0896	0,0702	0,0118	0,0395
pais	0,0118	0,0618	0,0657	0,0896	0,0118	0,0118	0,0395



Con este suavizado, ninguna probabilidad es cero. El ranking de documentos quedo de la siguiente manera:

doc	d1	d2	d3	d4	d5	d6
score	0,000140	0,003824	0,000778	0,008032	0,000831	0,000140

Comparando con el modelo anterior, el suavizado hace que los documentos que antes eran cero ahora tienen una probabilidad baja asociada. D4 sigue siendo considerado el documento con más score.

B) Consulta: país libre cultura

	d1	d2	d3	d4	d5	d6	P(Term Coleccion)
cultura	0,0118	0,0618	0,0118	0,0896	0,0702	0,0118	0,0395
libre	0,0704	0,0737	0,0237	0,1792	0,0820	0,0775	0,0789
pais	0,0118	0,0618	0,0657	0,0896	0,0118	0,0118	0,0395

El ranking de documentos quedo de la siguiente manera:

doc	d1	d2	d3	d4	d5	d6
score	0,000010	0,000282	0,000018	0,001440	0,000068	0,000011

Todos los documentos tienen un score asociado. Los dos documentos que no eran cero en el modelo anterior (D2 y D4), ahora tienen un score más bajo debido al suavizado aplicado, distribuyendo la probabilidad en los demás documentos.

C) Consulta: software propietario licencia

A pesar de aplicar el suavizado, los dos términos que están fuera del vocabulario siguen dando probabilidad cero.

	d1	d2	d3	d4	d5	d6	P(Term Coleccion)
software	0,1170	0,0237	0,0775	0,1792	0,0237	0,0775	0,0789
propietario	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000
licencia	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000

Por lo tanto, el ranking de documentos quedo de la siguiente manera:

doc	d1	d2	d3	d4	d5	d6
score	0,000000	0,000000	0,000000	0,000000	0,000000	0,000000

Al seguir usando Query Likelihood, el suavizado no soluciona la problemática de los términos fuera del vocabulario, teniendo el mismo problema que con MLE. Como resultado, los score de todos los documentos son cero.

2) Repita el ejercicio pero esta vez utilice la divergencia de Kullbak-Leiber y un suavizado por Dirichlet-Priors utilizando para los parámetros los valores sugeridos en la literatura.

Suavizado Dirichlet Priors

Construimos la matriz termino-documento con el suavizado Dirichlet Prioris, aplicando la siguiente fórmula para cada intersección.

$$P_{DP}(t|\theta_i) = \frac{f(t, d) + \mu \cdot P(t|\theta_C)}{|d| + \mu}$$

El mu utilizado para llevar a cabo el suavizado es 1000, sugerido en la literatura. Este nos garantiza un balance entre el documento y la colección.

Divergencia de Kullback-Leibler (KL)

Con la nueva matriz, calculamos el KL, que nos dará la distancia entre las distribuciones de la query y el documento. La fórmula es la siguiente:

$$KL(\theta_q|\theta_i) = \sum_t P(t|\theta_q) \cdot \log \frac{P(t|\theta_q)}{P(t|\theta_i)}$$

Aclaración: Es necesario también aplicar el suavizado de DP a las queries.

A) Consulta: país cultura

El suavizado queda de la siguiente manera

	d1	d2	d3	d4	d5	d6	MLE
cultura	0,0389	0,0399	0,0390	0,0401	0,0400	0,0390	0,0395
país	0,0389	0,0399	0,0400	0,0401	0,0390	0,0390	0,0395

Las probabilidades entre los términos y documentos son muy similares, haciendo que el suavizado cumpla un factor importante en el ranking posterior que, calculando el KL correspondiente, fue el siguiente:

Q1	doc	d1	d2	d3	d4	d5	d6
	país	0,0007	0,0002	0,0002	0,0001	0,0006	0,0006
	cultura	0,0007	0,0002	0,0006	0,0001	0,0002	0,0006
	KL	0,0013	0,0004	0,0008	0,0002	0,0008	0,0013

D4, al ser el documento con menor valor, es el mas similar a la query. Analizando su probabilidad con el suavizado, es el que probabilidad mas alta en ambos términos tiene (0,0401).



De igual manera, los valores de KL son muy similares entre todos los documentos, haciendo que todos ellos sean muy parecidos y relevantes para la query. Esto nos hace deducir que el suavizado junto con KL es poco confiable en casos donde los documentos son similares.

B) Consulta: país libre cultura

El suavizado queda de la siguiente manera

	d1	d2	d3	d4	d5	d6	MLE
cultura	0,0389	0,0399	0,0390	0,0401	0,0400	0,0390	0,0395
libre	0,0788	0,0788	0,0779	0,0802	0,0790	0,0789	0,0789
país	0,0389	0,0399	0,0400	0,0401	0,0390	0,0390	0,0395

El termino “libre” trae consigo probabilidades distintas a los dos términos utilizados en la anterior consulta, siendo el más predominante en la consulta.

El ranking queda de la siguiente manera:

Q2	doc	d1	d2	d3	d4	d5	d6
	país	-0,0006	-0,0002	-0,0002	-0,0001	-0,0006	-0,0006
	cultura	-0,0006	-0,0002	-0,0006	-0,0001	-0,0002	-0,0006
	libre	-0,0004	-0,0004	-0,0008	0,0002	-0,0003	-0,0003
	KL	-0,0017	-0,0008	-0,0016	0,0000	-0,0011	-0,0016

Como la consulta anterior, D4 sigue siendo el documento mas relevante para la query, ya que tiene la mayor probabilidad del termino “libre”; predominante en la query.

Los demás documentos, al tener probabilidades menores que D4, tiene un KL un poco mas distante pero no tan importante como para no considerarse relevante en el estudio.

C) Consulta: software propietario licencia

software	0,0798	0,0779	0,0789	0,0802	0,0780	0,0789	0,0789
propietario	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000
licencia	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000

A pesar de aplicar un suavizado, los dos términos que no forman parte del vocabulario siguen sin tener una probabilidad asociada, o es tan pequeña que no puede considerarse para el estudio.

Q3	doc	d1	d2	d3	d4	d5	d6
	software	0,0000186	-0,00081331	-0,00034342	0,00022385	-0,00074496	-0,00034342



	propietari o	#¡NUM!	#¡NUM!	#¡NUM!	#¡NUM!	#¡NUM!	#¡NUM!
	licencia	#¡NUM!	#¡NUM!	#¡NUM!	#¡NUM!	#¡NUM!	#¡NUM!
	KL	#¡NUM!	#¡NUM!	#¡NUM!	#¡NUM!	#¡NUM!	#¡NUM!

El único valor de KL que puede calcularse en este caso es para el termino “software” porque los dos términos que no pertenecen al vocabulario no permiten realizar el calculo del KL ya que estamos dividiendo por 0.

Analizando solamente el termino software, obviamente el documento con mayor probabilidad será quien sea considerado mas relevante, en este caso, D4.

Podemos concluir en este caso que el suavizado DF no considera los términos que están fuera del vocabulario, perjudicando el cálculo del KL.

3) Utilizando modelos de lenguaje en pyTerrier repita los experimentos del ejercicio 7 del TP de "modelos" y compare los resultados con los anteriores. ¿Son consistentes? Calcule las métricas apropiadas para comparar los diferentes sistemas y configuraciones.

Modelos de lenguaje en pyTerrier

Para el siguiente experimento, se utilizaron los siguientes modelos:

- TF-IDF (usado en el TP anterior)
- Jelinek-Mercer (JM), aplicando un lambda de 0.7
- Dirichlet Priors (DP), aplicando un mu de 1000

A) Análisis global

Los resultados para las métricas solicitadas fueron las siguientes:

	TF-IDF	JM	DP
P@10	0.3591	0.3215	0.2397

Para el P@10, el mejor rendimiento lo tiene TF-IDF, afirmando que, de los primeros 10 resultados, casi 4 documentos son relevantes. Podemos decir que es el modelo más efectivo para recuperar documentos más relevantes en el top de la colección.

El modelo JM, por su parte, reduce un poco su rendimiento con respecto a JM. Esto puede deberse al suavizado aplicado.

El modelo DP es el que peor valor de métrica presenta para P@10, donde 2 son relevantes dentro de los primeros 10.

	TF-IDF	JM	DP
AP	0.2909	0.2535	0.1960

TF-IDF también es considerado un mejor modelo para AP, indicando que tiene una mejor capacidad para el ordenamiento de relevantes, a pesar de ser un valor relativamente bajo (0.29).

JM y DP muestran un peor desempeño, dando por hecho que el suavizado no mejora la calidad del ranking

	TF-IDF	JM	DP
NDCG@10	0.4444	0.3947	0.2973


En la ultima métrica, TF-IDF sigue dominante, siendo el que mejor ordena los relevantes. JM y DP siguen teniendo un desempeño bajo, pero siempre Jelinek-Mercer superponiéndose.

En base a un análisis global de las métricas solicitadas, podemos decir que el mejor modelo global es TF-IDF, ya que fue el mejor en las tres métricas y tiene una mayor capacidad de discriminación en el documento trabajado (Vaswani). A este, le sigue JM, que tiene un rendimiento inferior al mejor, pero es mas estable que el ultimo en todas las métricas. Por último, DP es el peor modelo en esta colección, que puede deberse a un sobre suavizado de la colección, que haya perjudicado el rendimiento del mismo.

Faltaría por comprobar si, con una modificación fina de parámetros (λ y μ) fuera de los estipulados para este análisis, los modelos pueden mejorar su rendimiento en la colección trabajada.

B) Curva R-P

Calculadas las métricas para cada modelo, construimos la curva R-P de 11 puntos para cada uno, quedando de la siguiente manera:



El modelo TF-IDF presenta la precisión inicial mas alta (0.7254), seguido de Jelinek-Mercer (0.6779) y por ultimo Dirichlet Priors (0.5754).

En todos los niveles de Recall, excepto el ultimo, TF-IDF mantiene el mejor desempeño, aunque la diferencia con JM no es tan significativa. Entre el mejor modelo y el peor existe una diferencia notable de precisión en todos los puntos de recall, de 0.2 decimales.

Cuanto más aumenta el recall, los tres modelos reducen su precisión, convergiendo todos en un valor alrededor de 0.02 aproximadamente.


A partir del valor de recall 0.9, el modelo de DP toma un valor de precisión superior a los otros dos. En todo lo demás, se mantiene por debajo de los mismos. Esto da por sentado que presenta el peor ranking de todos.

Con el análisis de la curva R-P, se sigue confirmando que el mejor modelo sigue siendo TF-IDF

C) Análisis individual

Para el análisis por query, se muestra gráficamente como es la distribución de los valores en cada métrica.

P@10




Puede verse en el grafico como, de los 3 modelos, la mayor cantidad de querys que tienen en el top 10 los documentos mas relevantes ronda en valores de 0.1 a 0.4. Esto quiere decir que, de 10 documentos, hay entre 1 a 4 documentos relevantes.

Es interesante destacar como, en el modelo de Dirichlet, hay un aproximado de 20 queries que no devuelve ningún documento relevante, mas del doble de lo que sucede en los otros modelos. Esto explica en parte los resultados de las métricas calculadas anteriormente

Tanto TF-IDF como JM tienen distribuciones muy similares. DP difiere mucho en la distribución de estos dos modelos al tener muy pocas queries para valores altos de $P@10$; toda la distribución esta desplazada a la izquierda.

Con los gráficos provistos, podemos confirmar que TF-IDF también predomina en queries individuales para $P@10$

AP




TF-IDF presenta mas queries en valores medios, que rondan entre 0.3 y 0.6, aunque también tienen una cierta cantidad similar en valores bajos. JM no supera a el modelo mencionado por tener mas cantidad de queries en valores bajos que medios, haciendo así que tenga un menor rendimiento.

En Dirchlet, toda la distribución esta sesgada a la izquierda, teniendo una gran concentración en valores bajos de MAP, haciendo que el modelo tenga un pésimo rendimiento.

Confirmamos también que TF-IDF es mejor para el ranking completo, y JM supera a DP por tener una distribución mas ordenada y no tan sesgada.

NDCG@10



Del top 10, el modelo de Dirichlet es el que menos relevantes recupera, con un aproximado de 28 queries, el doble que el mejor modelo, que seria en nuestro caso TF-IDF, con un total de 14 queries; JM se queda en el medio entre ambos valores.

En rangos que van de 0.4 a 0.9, la distribución entre TF-IDF y JM se vuelve muy similar, abarcando buenos rangos en 10 a 15 queries. De igual manera, TF-IDF sigue dominando los rangos mas altos, afirmando que, una buena cantidad de consultas tienen un rendimiento alto. JM pierde fuerza más rápido a medida que nos acercamos a 1.0



Existe un caso particular a destacar en el modelo de Dirichlet, donde existe una query con valor 1.0

Conclusión

En base al análisis de gráficos y métricas, podemos concluir que el modelo TF-IDF es el mejor, seguido de Jelinek-Mercer con valores cercanos, y por ultimo Dirichlet Priors.

El rendimiento de estos dos últimos modelos vistos en clase esta sujeto a dos parámetros, que modificándolos en base a las características de la colección pueden hacer que las métricas se modifiquen y poder conseguir un modelo optimo que pueda superar al modelo clásico.

Utilización de IA:

Se le solicito la IA como se realiza la declaración de los dos modelos utilizados para llevar a cabo el análisis, además de la construcción de graficos solapados entre los tres modelos con plot.



Bibliografía

- [1] Ricardo Baeza-Yates and Berthier Ribeiro-Neto. Modern Information Retrieval: The Concepts and Technology Behind Search. Addison-Wesley Publishing Company, USA, 2nd edition, 2008.
- [2] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. Introduction to Information Retrieval. Cambridge University Press, New York, NY, USA, 2008.