



Trabajo Práctico
Recuperación de Información en la Web

Fecha de entrega: 10/06/2026

Josue Leonel Gatica Odato 178921

Josuegaticaodato@gmail.com





Aclaración importante sobre colecciones:

Para un correcto manejo de las colecciones en cada ejercicio, los archivos .py tomando las colecciones por defecto en una carpeta llamada “Colecciones”, ubicada a la par con todas las carpetas de los ejercicios.

En ejercicios donde no se indica el pasaje del directorio donde se encuentran los documentos como parámetro, este toma por defecto la carpeta indicada con el nombre de la colección que se solicitó analizar para ese ejercicio.

Herramienta de IA

El modelo de lenguaje de inteligencia artificial utilizado para el trabajo fue ChatGPT



1) Escriba un script Python que reciba como parámetro una URL y descargue la página HTML correspondiente. Luego, extraiga de la misma los enlaces y los muestre por consola.

Utilizando las librerías BeautifulSoup y requests, se construyó un script en Python que, dado una URL, descarga la página, extrae los enlaces y los muestra por consola.

El script se ejecuta de la siguiente manera:

```
python TP5/EJ1/EJ1.py <URL>
```

Para probarlo, se utilizó la página de Wikipedia de "Argentina", obteniendo un total de 7107 enlaces.

```
python TP5/EJ1/EJ1.py "https://es.wikipedia.org/wiki/Argentina"

Cantidad de enlaces: 7107
#bodyContent
/wiki/Wikipedia:Portada
/wiki/Portal:Comunidad
/wiki/Portal:Actualidad
/wiki/Especial:CambiosRecientes
...
```

En este caso, todos los enlaces no están normalizados, es por ello que fue necesario implementar un parser, buscando normalizar rutas relativas y absolutas. Aplicado esto, el resultado es:

```
python TP5/EJ1/EJ1.py "https://es.wikipedia.org/wiki/Argentina"

Cantidad de enlaces: 7107
https://es.wikipedia.org/wiki/Argentina
https://es.wikipedia.org/wiki/Wikipedia:Portada
https://es.wikipedia.org/wiki/Portal:Comunidad
https://es.wikipedia.org/wiki/Portal:Actualidad
https://es.wikipedia.org/wiki/Especial:CambiosRecientes
...
```

2) Modifique su programa anterior para implementar un crawler básico de acuerdo al algoritmo presentado en la siguiente figura

```
1: push(todo_list,initial_set_of_urls)
2: while todo_list[0] ≠ ∅ do
3:   page ← fetch_page(todo_list[0])
4:   if page downloaded then
5:     links ← parse(page)
6:     for all l in links do
7:       if l in done_list then
8:         push(todo_list[0].outlinks,done_list[l].id)
9:       else if l in todo_list then
10:        push(todo_list[0].outlinks,todo_list[l].id)
11:       else if l pass our filter then
12:        push(todo_list,l)
13:        todo_list[l].id = no. of url's
14:        push(todo_list[0].outlinks,todo_list[l].id)
15:       end if
16:     end for
17:   end if
18: end while
```

Luego, realice una pequeña recolección con los siguientes parámetros:

- a) Conjunto semilla: los 20 primeros sitios del ranking de Netcraft
- b) Cantidad Máxima de Páginas por sitio: [20-50]
- c) Profundidad Lógica Máxima: 3
- d) Profundidad Física Máxima: 3

Luego de la descarga, arme el grafo correspondiente. Grafique utilizando la librería pyvis


Se utilizo el siguiente conjunto semilla para ejecutar el crawler:

- 1. "https://www.google.com",
- 2. "https://www.youtube.com",
- 3. "https://mail.google.com",
- 4. "https://docs.google.com",
- 5. "https://www.facebook.com",
- 6. "https://outlook.office.com",
- 7. "https://chatgpt.com",
- 8. "https://login.microsoftonline.com",
- 9. "https://outlook.cloud.microsoft",
- 10. "https://accounts.google.com",
- 11. "https://campus-1001.ammon.cloud",
- 12. "https://www.linkedin.com",
- 13. "https://www.bing.com",
- 14. "https://drive.google.com",
- 15. "https://www.instagram.com",

16. "https://x.com",
17. "https://github.com",
18. "https://gemini.google.com",
19. "https://calendar.google.com",
20. "https://web.whatsapp.com"

Además, se limitó la cantidad de sitios totales a 1000.

El resultado fue el siguiente grafo (en la carpeta del EJ2 se encuentra el .html del grafo):




3) Realice un crawling de la página principal de ~~Amazon.com~~ unlu.edu.ar (solamente páginas dentro del dominio). Al finalizar, analice la distribución de páginas dinámicas y estáticas y la distribución de frecuencias por profundidad lógica y física.

Debido a que la página de Amazon no puede ser crawleada, se utilizó como página principal el dominio "unlu.edu.ar"

Ejecutado el crawling, se obtuvieron los siguientes resultados:

Distribución de paginas


Páginas Dinámicas vs Estáticas



Total de paginas	200
Dinámicas	78 (39%)
Estáticas	122 (61%)

En base a la distribución de las páginas, podemos ver como predomina más los sitios es estáticos que dinámicos en la web de la UNLu, que es normal en sitios institucionales donde es necesario mostrar un panorama claro y fijo de lo que es la institución. Sin embargo, la proporción de páginas dinámica es significativa, que puede deberse a que existen formularios y sistemas internos que se crean para otorgarle una experiencia personalizada y única a los usuarios que entre al sitio.

Distribución de profundidad lógica




Profundidad 0	84
Profundidad 1	106
Profundidad 2	10

Gran parte de las páginas están entre el nivel 0 y 1 de profundidad, dando por hecho que el sitio en general no tiene una estructura muy profundidad, fueron solamente diez las páginas que llegaron al nivel 2.

El crawling se realizó con la limitación de profundidad lógica hasta nivel 2, pero aumento esta limitación no debería aumentar la cantidad de páginas hasta el punto de emparejar los niveles principales, es probable que ronde en valores menores al nivel 2.

En términos de usabilidad, resulta positivo que el usuario llegue a la mayoría del contenido haciendo solamente uno o dos clics.

Distribución de profundidad física




Profundidad 0	117
Profundidad 1	83

La mayoría de los sitios crawleados están en la raíz, y la rutas solamente llegan a una forma “/a”. A pesar de establecer una profundidad máxima de 2, no se encontró ninguna página que llegue a esta profundidad.

Grafo del sitio

De las 200 páginas visitadas establecidas como límite para crawllear, se obtuvieron 329 nodos, esto indica que existen sitios todavía sin explotar por las limitaciones del crawler.

Gráficamente, se puede ver el grafo de la siguiente manera:



Redondeado con rojo, es la URL principal ("unlu.edu.ar"), que contiene la gran cantidad de enlaces de todo el sitio.

Todos los demás subgrafos que se arman son los diferentes subdominios que existen en la página, que tienen muy pocos enlaces. El que mas enlaces destacada es el redondeado con color azul, que es el subdominio "edunlu".


Utilización de IA:

Fue necesaria la utilización de la inteligencia artificial para la construcción del grafo y los gráficos necesarios para hacer el posterior análisis.

4) Suponga que se han recuperado un conjunto de páginas de un pequeño repositorio de sólo seis utilizando el modelo de espacio vectorial. Dado un query Q se produjo la salida de la siguiente con los valores de $\text{sim}(Q, D_i)$.

Pos	Doc	Score
1	E	4.9734
2	C	4.8173
3	A	2.5617
4	B	2.0110
5	D	0.8937
6	F	0.0000

Las páginas se encuentran vinculadas de acuerdo al siguiente grafo:



- Calcule los valores de PageRank de las páginas utilizando como factor de damp 0.15 y 0.5. Pruebe iterando 2, 5 y 10 veces.
- Use los valores de PageRank para re-ranear la salida de la búsqueda interpolando los valores (controlado por un parámetro α). ¿Se altera el ranking? ¿En qué caso? Comente los resultados.

A) PageRank

Utilizando la fórmula de PageRank provista en clase, se calcularon los valores para un factor de damp de 0.15 y 0.5, obteniendo los siguientes resultados iterando 2,5 y 10 veces.



N	6		Calculo de Page-Rank con $d = 0,50$			
d	0,5					
$(1-d)/n$	0,08333333					
Step	A	B	C	D	E	F
0	0,16666667	0,166667	0,166667	0,166667	0,166667	0,166667
1	0,27777778	0,125	0,194444	0,194444	0,083333	0,125
2	0,20833333	0,152778	0,201389	0,201389	0,083333	0,152778
3	0,22685185	0,135417	0,209491	0,209491	0,083333	0,135417
4	0,21527778	0,140046	0,210648	0,210648	0,083333	0,140046
5	0,2183642	0,137153	0,211998	0,211998	0,083333	0,137153
6	0,21643519	0,137924	0,212191	0,212191	0,083333	0,137924
7	0,21694959	0,137442	0,212416	0,212416	0,083333	0,137442
8	0,21662809	0,137571	0,212449	0,212449	0,083333	0,137571
9	0,21671382	0,13749	0,212486	0,212486	0,083333	0,13749
10	0,21666024	0,137512	0,212491	0,212491	0,083333	0,137512

Con verde, las iteraciones solicitadas

N	6		Calculo de Page-Rank con $d = 0,15$			
d	0,15					
$(1-d)/n$	0,14166667					
Step	A	B	C	D	E	F
0	0,16666667	0,166667	0,166667	0,166667	0,166667	0,166667
1	0,2	0,154167	0,175	0,175	0,141667	0,154167
2	0,19375	0,156667	0,175625	0,175625	0,141667	0,156667
3	0,19425	0,156198	0,175844	0,175844	0,141667	0,156198
4	0,19415625	0,156235	0,175853	0,175853	0,141667	0,156235
5	0,19416375	0,156228	0,175856	0,175856	0,141667	0,156228
6	0,19416234	0,156229	0,175857	0,175857	0,141667	0,156229
7	0,19416246	0,156229	0,175857	0,175857	0,141667	0,156229
8	0,19416244	0,156229	0,175857	0,175857	0,141667	0,156229
9	0,19416244	0,156229	0,175857	0,175857	0,141667	0,156229
10	0,19416244	0,156229	0,175857	0,175857	0,141667	0,156229

Como puede verse, de las iteraciones de 2 a 5, se llegan a valores muy similares entre ambos que, considerando un ϵ determinado, puede decirse que ya se produjo una convergencia. Desde las iteraciones 5 a 10, los valores varían muy poco, solamente en 3 o 4 unidades después de la coma. Esto sucede con ambos valores de d solicitados.

Para un factor de $d = 0.5$, los scores de los documentos A, B y D se alejan de los demás, siendo estos tres mencionados muy parecidos. El documento E es el que menor score tiene, y resulta de interés mencionarlo ya que el score calculado por similitud lo toma como el documento más relevante de los seis; este es un claro ejemplo de cómo, al no tener enlaces entrantes, pagerank hace que su score sea menor. El documento A, que tiene la mayor cantidad de enlaces entrantes (3), es el documento con más score.

Para un factor de $d = 0.15$, no hay tanta diferencia entre los scores de documentos y están todos muy cerca entre sí, siendo más uniforme.

Como análisis general entre los dos factores, el primero les da más importancia a los enlaces, es por ello que el documento con más score previo termina siendo el peor en pagerank, y el segundo factor le da menos importancia a los enlaces y distribuye más uniformemente los scores, sin que los documentos se saquen tanta diferencia.

B) Re-Rankeo

Calculados los valores de pagerank, se procedió a re-ranquear los documentos interpolando los valores con diferentes valores de α , teniendo lo siguiente:

Para $\alpha = 0,2$

$\alpha * \text{Score} + (1-\alpha) * \text{PR}$						α	0,2
$d = 0,5$				$d = 0,15$			
Pos	Doc	Score		Pos	Doc	Score	
1	C	1,133453		1	E	1,108013	
2	E	1,061347		2	C	1,104145	
3	A	0,685668		3	A	0,66767	
4	B	0,512209		4	B	0,527183	
5	D	0,348733		5	D	0,319425	
6	F	0,110009		6	F	0,124983	

A pesar de darle más importancia al pagerank sobre el score ya calculado por similitud, el ranking se mantiene de la misma manera para el d de 0.15, pero para el d de 0.5 hay una variación entre el top 1 y el top 2, donde el documento C pasa a ser el más relevante.

Para $\alpha = 0,5$

$\alpha * \text{Score} + (1-\alpha) * \text{PR}$						α	0,5
d = 0,5			d = 0,15				
Pos	Doc	Score	Pos	Doc	Score		
1	E	2,528367	1	E	2,557533		
2	C	2,514896	2	C	2,496578		
3	A	1,38918	3	A	1,377931		
4	B	1,074256	4	B	1,083614		
5	D	0,553096	5	D	0,534778		
6	F	0.068756	6	F	0.078114		

Como un parámetro que pondera por igual el score y el pagerank, no varia el ranking de los documentos y este se mantiene igual, sin importar el factor de dump.

Para $\alpha = 0,9$

$\alpha * \text{Score} + (1-\alpha) * \text{PR}$						α	0,9
d = 0,5			d = 0,15				
Pos	Doc	Score	Pos	Doc	Score		
1	E	4,484393	1	E	4,490227		
2	C	4,356819	2	C	4,353156		
3	A	2,327196	3	A	2,324946		
4	B	1,823651	4	B	1,825523		
5	D	0,825579	5	D	0,821916		
6	F	0,013751	6	F	0,015623		

En este caso, se considera más el score ya calculado sobre el pagerank, haciendo el ranking no se modifique en ninguno de los dos factores de dump.

Como conclusión, se puede decir que el ranking no cambia en ninguno de los casos a excepción del caso particular del primer alfa en el factor de dump 0.5. En todos los casos, el documento E es el mas relevante, como se había determinado previamente en la similitud, y el documento F sigue siendo el peor de todos, ya que su score inicial es cero.

5) Usando su crawler realice una recolección de 500 páginas. Luego, calcule para cada una los valores de PageRank y Authorities (HITS) utilizando la librería NetworkX Simule un crawling siguiendo el orden de acuerdo al valor de PageRank de las páginas (de mayor a menor). Grafique la evolución del porcentaje de overlap respecto del orden por valor de Auth para ambas estrategias de crawling. Explique su resultado.

Se realizó la recolección de 500 páginas, teniendo como semilla el sitio de la UNLu (unlu.edu.ar)


Resultados de la simulación

Métricas	PageRank	FIFO
25%	4	27
50%	14	31
75%	17	42
100%	27	70

Lo que se trata de mostrar en el gráfico de resultados es la cantidad de páginas que son necesarias para abarcar el % correspondiente al top-k establecido. Por ejemplo, para PageRank fue necesario recorrer 4 páginas para abarcar el 25% del top-k. En este caso, se trabajó con un $k = 50$.


Comparando PageRank con FIFO, que sería el orden común que vienen las páginas, puede verse como el algoritmo supera en todas las métricas, esto quiere decir que encuentra páginas relevantes mucho más rápido.

La explicación de esto es que las páginas con alto PageRank actúan como puentes o hubs estructurales. Al visitar primero los nodos más populares de la red, el crawler accede rápidamente a los enlaces salientes que apuntan a las verdaderas autoridades. FIFO, por el contrario, pierde tiempo explorando ramas o niveles del árbol de enlaces que puede ser páginas sin salida o con baja relevancia.



En rojo, se demuestra como PageRank supera ampliamente a FIFO, cubriendo rápidamente gran parte del top y acercándose al 100%. En contraste, al orden de descubrimiento le toma mas tiempo y necesita mucho más paginas para lograr lo mismo.


Correlación entre Pagerank e HITS



Calculando la correlación entre ambos algoritmos, se demuestra que ambos no miden lo mismo y tienen relación positiva muy débil.

Para concluir, decimos que priorizar paginas con alto PageRank no garantiza directamente que estas paginas tengan un alto valor de autoridad, que se demuestran en base a los outliers presentes en el grafico y la poca correlación entre ambos.

Tops para Pagerank e HITS



Para ambos algoritmos, los seis primeros puestos los ocupa guiatel.unlu.edu.ar. A partir de ahí, difieren ambos en las paginas que colocan en el top.

Existe paginas repetidas en el top debido a los parámetros de sesión en la query



Utilización de IA:

Fue necesaria la utilización de la inteligencia artificial para la construcción de la simulación entre ambos algoritmos y los gráficos necesarios para hacer el posterior análisis.



Bibliografía

- [1] Ricardo Baeza-Yates and Berthier Ribeiro-Neto. Modern Information Retrieval: The Concepts and Technology Behind Search. Addison-Wesley Publishing Company, USA, 2nd edition, 2008.
- [2] Bruce Croft, Donald Metzler, and Trevor Strohman. Search Engines: Information Retrieval in Practice. Addison-Wesley Publishing Company, USA, 1st edition, 2009.
- [3] R. Fielding, J. Gettys, J. Mogul, H. Frystyk, L. Masinter, P. Leach, and T. Berners-Lee. Rfc2616 - hypertext transfer protocol – http/1.1. Technical report, United States, 1999.
- [4] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schutze. Introduction to Information Retrieval. Cambridge University Press, New York, NY, USA, 2008.